

Summary Report

DETEKSI KUALITAS AIR MENGGUNAKAN SUPPORT VECTOR MACHINE DAN REGRESI LOGISTIK BINER

Mata Kuliah Praktik Statistika Teknologi Informasi

Dosen Pengampu

Annisatul Nikmah, S.Tr.Stat., M.Stat

Disusun Oleh

KELOMPOK 2

Anggota Kelompok:

- Gahzy Octaviano Ramadhan V3423037
- Gustavito Fajrul Izzati D.P V3423039
- Lafiga Rizki Hanata V3423049
- Muhammad Fadhli Nur Luthfan V3423055
- Muhammad Haekal Alif Putra V3423056



Table Of Content

<u>PENDAHULUAN</u>	02
<u>METODE ANALISIS</u>	04
<u>HASIL DAN PEMBAHASAN</u>	06
<u>KESIMPULAN DAN SARAN</u>	12
<u>DAFTAR PUSTAKA</u>	12

Pendahuluan

LATAR BELAKANG

Air adalah sumber daya penting yang menopang kehidupan manusia dan berbagai makhluk hidup lainnya. Namun, kualitas air di berbagai belahan dunia terus terancam oleh berbagai faktor, termasuk limbah domestik, limbah industri, dan perubahan iklim. Menurut Freitas Muniz (2023), analisis kualitas air tidak hanya menjadi bagian penting dari pengelolaan sumber daya air, tetapi juga menjadi alat untuk mendeteksi potensi bahaya dan melindungi ekosistem akuatik. Selain itu, krisis air bersih yang terus meningkat, terutama di negara-negara berkembang, menekankan pentingnya analisis mendalam terhadap parameter-parameter air untuk memastikan keberlanjutan akses terhadap sumber daya ini.

Selain penting untuk kebutuhan domestik, air juga menjadi elemen utama dalam sektor industri, pertanian, dan kesehatan. Pencemaran air dapat memicu berbagai dampak negatif, seperti gangguan kesehatan akibat penyakit bawaan air, penurunan hasil pertanian, dan kerusakan lingkungan yang signifikan (Jamaludin, 2022). Sebagai contoh, kasus pencemaran di Danau Toba menunjukkan bagaimana limbah rumah tangga, industri, dan transportasi publik dapat berdampak pada kesehatan masyarakat setempat dan menurunkan kualitas destinasi pariwisata. Oleh karena itu, penting untuk mengidentifikasi parameter yang menentukan kelayakan air guna mengurangi dampak negatif tersebut.

Menurut Roy (2018), kualitas air dapat dinilai melalui parameter fisik, kimia, dan biologi, yang memberikan gambaran lengkap tentang kondisi air. Parameter ini tidak hanya membantu mendeteksi tingkat pencemaran tetapi juga memastikan bahwa air memenuhi standar kesehatan yang berlaku. Di era modern, penggunaan teknologi seperti analisis statistik multivariat semakin berkembang untuk mengevaluasi data kualitas air, memungkinkan pengambilan keputusan yang lebih efisien dan berbasis data. Analisis seperti ini juga dapat memberikan wawasan tentang pola jangka panjang kualitas air, yang relevan untuk perencanaan sumber daya air di masa depan.

Pendahuluan

TUJUAN

- Menghasilkan model regresi logistik untuk memprediksi potabilitas air, serta mengevaluasi signifikansi parameter yang digunakan.
- Membuat model klasifikasi menggunakan metode Support Vector Machine (SVM) dengan kernel dan parameter terbaik untuk memprediksi potabilitas air.
- Membandingkan hasil dari regresi logistik dan SVM berdasarkan metrik evaluasi seperti akurasi, precision, recall, F1-score, dan AUC untuk menentukan metode yang lebih efektif.

RUMUSAN MASALAH

- Bagaimana hasil analisis regresi logistik dalam memprediksi potabilitas air, termasuk parameter signifikan yang memengaruhi prediksi?
- Bagaimana hasil analisis Support Vector Machine (SVM) dalam memprediksi potabilitas air dengan kernel dan parameter yang optimal?
- Metode analisis mana yang lebih unggul antara regresi logistik dan SVM dalam memprediksi potabilitas air berdasarkan metrik evaluasi?

MANFAAT

1. Manfaat Akademik:

- Memberikan kontribusi dalam literatur ilmiah tentang analisis kualitas air berbasis data.
- Memperkaya metode analisis dalam menentukan potabilitas air melalui pendekatan statistik.

2. Manfaat Praktis:

- Membantu pemerintah, penyedia layanan air, dan pengambil kebijakan dalam menetapkan strategi peningkatan kualitas air.
- Menyediakan informasi bagi masyarakat untuk lebih memahami pentingnya kualitas air dalam kehidupan sehari-hari.

3. Manfaat Lingkungan:

- Mendukung upaya pelestarian sumber daya air melalui pengelolaan yang lebih efektif.
- Mengurangi dampak pencemaran terhadap lingkungan dan kesehatan manusia.

Metode Analisis

SUMBER DATA

Dataset ini digunakan untuk mengevaluasi kualitas air berdasarkan beberapa parameter kimia dan fisik, serta memprediksi apakah air layak untuk diminum (potable). Dataset berisi 3276 baris data dan 10 kolom. Kolom target adalah Potability, sedangkan kolom lainnya adalah parameter kualitas air.

Link Dataset

<https://www.kaggle.com/datasets/adityakadiwal/water-potability>

VARIABLE PENELITIAN

Variable	Keterangan	Skala	Kategori
X1	ph	Interval	Tingkat keasaman atau kebasaan air dalam skala pH.
X2	Hardness	Interval	Kekerasan air, mengukur kandungan ion kalsium dan magnesium (mg/L).
X3	Solids	Interval	Jumlah padatan terlarut dalam air (mg/L).
X4	Chloramines	Interval	Kandungan kloramin, senyawa desinfeksi (mg/L).
X5	Sulfate	Interval	Kandungan ion sulfat yang mempengaruhi rasa air (mg/L).
X6	Conductivity	Interval	Kemampuan air untuk menghantarkan listrik ($\mu\text{S}/\text{cm}$).
X7	Organic_carbon	Interval	Jumlah karbon organik terlarut dalam air (mg/L).
X8	Trihalomethanes	Interval	Senyawa sampingan desinfeksi air (mg/L).
X9	Turbidity	Interval	Kekeruhan air (NTU).
Y	Potability	Nominal	0 : Tidak layak minum 1 : Layak diminum

Metode Analisis

LANGKAH ANALISIS

1. Persiapan Dataset:

- Menampilkan deskripsi dataset.
- Mengidentifikasi nilai kosong pada dataset.

2. Exploratory Data Analysis (EDA):

- Analisis statistik deskriptif untuk setiap variabel.
- Visualisasi distribusi data (histogram).
- Matriks korelasi antar variabel.
- Distribusi kategori

3. Penanganan Missing Values:

- Mengisi nilai kosong menggunakan median.

4. Pembangunan Model:

- Regresi Logistik: Membuat model untuk memprediksi potabilitas air dan mengidentifikasi parameter signifikan.
- Support Vector Machine (SVM): Menggunakan kernel (RBF, linear, polynomial) untuk membandingkan performa klasifikasi.

5. Evaluasi Model:

- Menggunakan metrik akurasi, precision, recall, F1-score, dan AUC untuk membandingkan performa metode.

Hasil dan Pembahasan


EXPLORATORY DATA ANALYSIS (EDA)

Statistik Deskriptif

Tabel statistik deskriptif diatas menggambarkan variasi kualitas air dengan rata-rata pH 7.08, menunjukkan sebagian besar air bersifat netral. Beberapa variabel seperti Hardness, Solids, dan Conductivity menunjukkan variasi yang besar, sementara Chloramines, Sulfate, dan Organic Carbon relatif stabil. Turbidity memiliki kekeruhan rata-rata 3.97 NTU, dan Potability menunjukkan bahwa 39% sampel air layak minum. Variasi antar variabel ini mencerminkan kualitas air yang bervariasi dalam dataset.

Variabel	Mean	Std Dev	Min	25%	50%	75%	Max
Ph	7.08	1.59	0.00	6.09	7.04	8.06	14.00
Hardness	196.37	32.88	47.43	176.85	196.97	216.67	323.12
Solids	22014.09	8768.57	320.94	15666.69	20927.83	27332.76	61227.20
Chloramines	7.12	1.58	0.35	6.13	7.13	8.11	13.13
Sulfate	333.78	41.42	129.00	307.70	333.07	359.95	481.03
Conductivity	426.21	80.82	181.48	365.73	421.88	481.79	753.34
Organic_carbon	14.28	3.31	2.20	12.07	14.22	16.56	28.30
Trihalomethanes	66.40	16.18	0.74	55.84	66.62	77.34	124.00
Turbidity	3.97	0.78	1.45	3.44	3.96	4.50	6.74
Potability	0.39	0.49	0.00	0.00	0.00	1.00	1.00

Distribusi Data (Histogram)





Pada Gambar disamping menunjukkan distribusi data untuk beberapa variabel. Sebagian besar variabel, seperti pH, Hardness, Chloramines, Sulfate, Conductivity, Organic Carbon, Trihalomethanes, dan Turbidity memiliki distribusi yang mendekati normal. Variabel Solids menunjukkan distribusi yang condong ke kanan (skewness positif), sedangkan Potability memiliki distribusi biner yang tidak seimbang, dengan mayoritas data pada kategori 0 (tidak dapat diminum). Secara umum, data cukup terpusat dengan beberapa variasi skewness pada variabel tertentu.

Hasil dan Pembahasan

Korelasi Antar Variable

- Tidak ada nilai korelasi yang sangat tinggi (mendekati +1 atau -1), yang berarti tidak ada hubungan linear yang kuat antara dua variabel apa pun dalam dataset ini.
- Hubungan yang lemah ini mengindikasikan bahwa analisis yang lebih kompleks, seperti regresi atau metode machine learning, mungkin diperlukan untuk memahami interaksi antara variabel terhadap potabilitas air.



Distribusi Kategori Potability

Gambar menunjukkan distribusi kategori Potability dalam dataset, dengan nilai 0 mewakili air yang tidak layak diminum dan nilai 1 mewakili air yang layak diminum. Distribusi ini tidak seimbang, di mana jumlah kategori 0 jauh lebih besar dibandingkan kategori 1. Sebagian besar sampel dalam dataset termasuk dalam kategori "tidak layak diminum" (sekitar 2000), sedangkan hanya sebagian kecil yang masuk kategori "layak diminum" (sekitar 1200).

Penanganan Missing Value

Tabel menunjukkan penanganan missing value pada dataset, di mana variabel pH, Sulfate, dan Trihalomethanes memiliki nilai yang hilang sebelum proses penanganan, masing-masing sebanyak 491, 781, dan 162. Missing value ini diatasi dengan mengisi nilai yang hilang menggunakan median. Metode ini dipilih karena median lebih robust terhadap outlier dibandingkan mean, sehingga mampu menjaga representasi distribusi data secara lebih akurat. Setelah penanganan, semua missing value berhasil diisi (bernilai 0), memastikan dataset lengkap dan siap untuk analisis lebih lanjut.

variable	sebelum	sesudah
Ph	491	0
Hardness	0	0
Solids	0	0
Chloramines	0	0
Sulfate	781	0
Conductivity	0	0
Organic_carbon	0	0
Trihalomethanes	162	0
Turbidity	0	0
Potability	0	0

REGRESI LOGISTIK BINER

Pemodelan regresi logistik biner dilakukan pada data training yang terdiri dari 70% dari total data (data_train) dan sisanya (data_test) untuk pengujian model. Variabel prediktor yang digunakan adalah pH, Kekerasan, dan Sulfate.

Model pertama yang dibangun adalah sebagai berikut:

$$\text{Potability} = \text{Intercept} + \beta_1 \cdot \text{pH} + \beta_2 \cdot \text{Hardness} + \beta_3 \cdot \text{Sulfate}$$

Hasil dari uji koefisien regresi menunjukkan nilai p-value untuk variabel-variabel prediktor lebih besar dari 0.05, yang berarti tidak ada variabel prediktor yang signifikan mempengaruhi variabel respon. Berikut adalah tabel koefisien regresi model pertama:

Coefficients	Estimate	Std. Error	z value	P value
(Intercept)	0.543094	0.528862	1.027	0.304
pH	-0.016276	0.029507	-0.552	0.581
Hardness	-0.001897	0.001307	-1.451	0.147
Sulfate	-0.001491	0.001190	-1.254	0.210

Dari hasil tersebut, dapat disimpulkan bahwa tidak ada variabel yang berpengaruh signifikan terhadap potabilitas air.

Uji Serentak dan Uji Parsial

Pada uji serentak, didapatkan nilai $G^2 = 3.802$, yang lebih kecil dari nilai kritis dari distribusi chi-square (7.814), sehingga hipotesis nol (H_0) diterima. Artinya, tidak ada pengaruh signifikan dari variabel-variabel prediktor terhadap variabel respon. Hasil uji serentak ini juga sejalan dengan hasil uji parsial yang menunjukkan p-value lebih besar dari 0.05.

Model Kedua (Pemodelan Terbaik)

Model kedua dibangun dengan menggunakan variabel pH dan Sulfate sebagai prediktor. Hasil dari model kedua menunjukkan bahwa variabel-variabel ini masih tidak signifikan dengan nilai p-value masing-masing di atas 0.05:

Coefficients	Estimate	Std. Error	z value	P value
(Intercept)	0.138923	0.449408	0.309	0.757
pH	-0.019718	0.029415	-0.670	0.503
Sulfate	-0.001323	0.001184	-1.118	0.264

Karena semua nilai p-value untuk pH, Hardness, dan Sulfate lebih besar dari 0.05, maka kita tidak dapat menolak hipotesis nol untuk masing-masing variabel. berarti tidak ada variabel prediktor yang signifikan secara statistik dalam model regresi logistik ini untuk memprediksi potabilitas air.

Uji Kesesuaian Model (Goodness of Fit)

Dilakukan uji kesesuaian model menggunakan uji Hosmer and Lemeshow, yang menghasilkan p-value sebesar 0.532. Hal ini menunjukkan bahwa model ini cukup fit dan tidak ada masalah kesesuaian antara model dan data.

Evaluasi Model

Akurasi	Sensitivitas	Spesifisitas
0.3876	0.0000	1.0000

Hasil confusion matrix menunjukkan bahwa model tidak dapat memprediksi dengan baik kelas positif, karena tidak ada prediksi yang benar untuk kelas positif (nilai sensitivitas 0). Namun, model sangat spesifik dalam memprediksi kelas negatif, dengan spesifisitas 1.0000.

Optimal Threshold

Nilai ambang batas optimal yang ditemukan adalah 0.3916, yang digunakan untuk menentukan klasifikasi kelas positif dan negatif dalam data pengujian.


Odds Ratio

Koefisien	Odds Ratio
(Intercept)	1.149
ph	0.980
Sulfate	0.999

Dari hasil ini, kita dapat menyimpulkan bahwa variabel pH dan Sulfate memiliki odds ratio yang sangat dekat dengan 1, yang menandakan pengaruh yang sangat kecil terhadap probabilitas potabilitas air.

MENGANALISIS SVM

Trial	Kernel	Degree	C	Gamma	Accuracy	AUC
1	rbf	-	1	0.01	0.6378	0.6819
2	rbf	-	100	0.01	0.6857	0.7055
3	linear	-	10	0.01	0.6277	0.5105
4	rbf	-	1	0.1	0.6907	0.7030
5	poly	2	1	0.01	0.6297	0.6874



1. Analisis ROC Curve

- **AUC (Area Under the Curve):** Nilai AUC adalah 0.71, yang menunjukkan bahwa model SVM memiliki kemampuan klasifikasi yang sedang (moderate). Semakin dekat nilai AUC ke 1, semakin baik performa model dalam membedakan antara kelas positif dan negatif.
- **Kurva ROC:** Kurva ROC menunjukkan trade-off antara True Positive Rate (TPR) dan False Positive Rate (FPR). ROC curve yang naik ke arah kiri atas menunjukkan performa yang lebih baik. Dalam hal ini, kurva berada di atas garis diagonal (garis acak), yang menunjukkan bahwa model lebih baik daripada tebakan acak.

2. Metrik Evaluasi Lainnya

- **Accuracy (0.6857):** Akurasi model adalah 68.57%, artinya model mengklasifikasikan 68.57% dari sampel dengan benar. Namun, akurasi saja tidak cukup untuk menilai performa, terutama pada dataset yang tidak seimbang.
- **Precision (0.7176):** Precision menunjukkan bahwa dari semua prediksi kelas positif (Potability = 1), sekitar 71.76% benar-benar positif. Precision tinggi mengindikasikan bahwa model baik dalam meminimalkan False Positives.
- **Recall (0.2568):** Recall menunjukkan bahwa model hanya mampu mendeteksi 25.68% dari total sampel positif sebenarnya. Nilai ini rendah, artinya model sering gagal mendeteksi kelas positif (tinggi False Negatives).

PERBANDINGAN REGRESI LOGISTIK BINER DAN SVM

Metrik Evaluasi	Regresi Logistik	SVM	Penjelasan dan Alasan
Akurasi	38.76%	68.57%	SVM memiliki akurasi lebih tinggi karena mampu memanfaatkan non-linearitas dalam data, sementara regresi logistik hanya efektif pada data yang terdistribusi linear.
Precision	Tidak dapat dihitung	71.76%	Regresi logistik gagal mendeteksi kelas positif, menghasilkan precision nol. SVM lebih baik dalam meminimalkan False Positives, menghasilkan precision tinggi.
Recall (Sensitivitas)	0%	25.68%	Recall regresi logistik nol karena tidak ada True Positives. SVM memiliki recall rendah tetapi masih dapat mendeteksi beberapa kasus positif.
Specificity	100%	Tidak dihitung	Regresi logistik sangat baik dalam memprediksi kelas negatif karena hanya memprediksi kelas tersebut. Spesifisitas pada SVM tidak dihitung secara eksplisit tetapi cenderung moderat.
AUC	Tidak dihitung	0.71	AUC SVM menunjukkan kemampuan sedang dalam membedakan antara kelas positif dan negatif. Regresi logistik tidak memberikan hasil signifikan untuk menghitung AUC.
Kompleksitas Data	Rendah	Tinggi	SVM cocok untuk dataset dengan distribusi non-linear seperti ini. Regresi logistik lebih sederhana tetapi kurang mampu menangani data non-linear.
Parameter yang Dibutuhkan	Minimal (koefisien sederhana)	Cukup banyak (kernel, margin)	Regresi logistik hanya membutuhkan koefisien parameter, sedangkan SVM memerlukan pengaturan parameter seperti kernel dan hyperparameter lainnya, membuatnya lebih kompleks.
Waktu Komputasi	Cepat	Relatif lambat	Regresi logistik lebih cepat karena memiliki struktur linear. SVM memerlukan waktu lebih lama karena perhitungan margin dan kernel, terutama pada dataset yang besar.
Kinerja pada Dataset	Buruk	Baik	Regresi logistik gagal memprediksi kelas positif, sementara SVM menunjukkan performa yang jauh lebih baik untuk dataset ini.

Kesimpulan dan Saran

Kesimpulan

Regresi Logistik gagal memprediksi potabilitas air dengan baik, menghasilkan akurasi rendah (38.76%) dan tidak mampu mendeteksi kelas positif (recall 0%). Meskipun memiliki spesifisitas 100%, model ini tidak efektif untuk dataset ini.

SVM menunjukkan performa lebih baik dengan akurasi 68.57%, precision 71.76%, dan recall 25.68%. Meskipun recall masih rendah, SVM lebih baik dalam mendeteksi kelas positif dibandingkan regresi logistik. AUC 0.71 menunjukkan kemampuan SVM dalam membedakan kelas.

Perbandingan Hasil:

SVM lebih unggul dalam memprediksi potabilitas air, terutama dalam akurasi, precision, dan recall. SVM lebih efektif dalam menangani data kompleks, meskipun membutuhkan waktu komputasi yang lebih lama dan pengaturan parameter lebih rumit.

Regresi Logistik lebih cepat tetapi kurang efektif pada dataset ini.

Saran

Penanganan Ketidakseimbangan Kelas:

Menggunakan metode seperti SMOTE atau teknik sampling lain untuk menangani ketidakseimbangan kelas dan meningkatkan recall.

Eksplorasi Model Lain:

Mencoba Random Forest atau Neural Networks untuk perbandingan lebih lanjut dan memilih model terbaik.

Optimasi Parameter SVM:

Melakukan tuning parameter SVM untuk meningkatkan performa, terutama recall.

Penambahan Fitur:

Menambah fitur yang relevan dengan kualitas air untuk meningkatkan akurasi dan daya prediksi model.

Daftar Pustaka

1. Freitas Muniz, D. H., & Oliveira-Filho, E. C. (2023). Multivariate Statistical Analysis for Water Quality Assessment: A Review. *Hydrology*, 10(10), 196. MDPI. <https://doi.org/10.3390/hydrology10100196>
2. Jamaludin, J., Zainul Ariffin, K. N., & Wan Ahmad Kamil, W. M. (2022). Advancements in Monitoring Water Quality Based on Various Sensing Methods: A Systematic Review. *International Journal of Environmental Research and Public Health*, 19(21), 14080. MDPI. <https://doi.org/10.3390/ijerph192114080>
3. Roy, S. (2018). An Introduction to Water Quality Analysis. *ESSENCE – International Journal for Environmental Rehabilitation and Conservation*, 9(2), 94–100. ResearchGate. https://www.researchgate.net/publication/328198997_An_Introduction_to_Water_Quality_Analysis